

BENINSCOPE — TERROIR

Plateforme de veille territoriale quasi temps réel pour le Bénin

Rapport technique et analytique

Hackathon iSHEERO x DataCamp 2026 | Equipe 04 | 29 mai 2026

Sommaire

1. Résumé exécutif
2. Contexte et problématique
3. Architecture du système
4. Pipeline de données GDELT
5. Score de Tension Territorial (STT)
6. Plateforme web TERROIR
7. Insights clés et résultats
8. Déploiement et infrastructure
9. Divulgence IA
10. Limitations et travaux futurs
11. Equipe et stack technique

1. Résumé exécutif

BéninScope — TERROIR est une plateforme de veille sécuritaire et territoriale destinée au Bénin, développée dans le cadre du Hackathon iSHEERO x DataCamp 2026. Elle répond à un besoin concret : agréger, structurer et rendre exploitables les signaux d'événements géopolitiques et sécuritaires disponibles dans les flux médiatiques internationaux, en les croisant avec des signalements citoyens géolocalisés.

La plateforme ingère en continu les données GDELT v2 (Global Database of Events, Language, and Tone), soit plus de 31 500 événements référencés sur le Bénin entre janvier 2025 et fin mai 2026. Un algorithme composite, le Score de Tension Territorial (STT), synthétise par département les dimensions de conflictualité, de tonalité médiatique, de volume et de diversité des sources, sur une fenêtre glissante de 14 jours comparée à un baseline de 90 jours.

La plateforme est accessible via une interface web interactive (carte Leaflet, clustering de marqueurs, filtres temporels) et un tableau de bord analytique Streamlit. Elle est déployée en continu sur Railway (backend FastAPI) et Streamlit Community Cloud (dashboard).

Volume de données	31 529 événements GDELT, janvier 2025 — mai 2026
Latence GDELT	15 minutes (cycle de polling automatique)
Couverture	12 départements du Bénin, coordonnées enrichies par priorité
Déploiement	Railway (API) + Streamlit Cloud (dashboard), GitHub CI/CD
Signalements	Module citoyen géolocalisé avec validation croisée GDELT

2. Contexte et problématique

2.1 Déséquilibre de la couverture médiatique

L'analyse des données GDELT sur le Bénin révèle un déséquilibre structurel majeur : les départements du nord — Alibori, Atacora, Borgou — ne représentent que 4 % de la couverture médiatique internationale attribuée au pays. Or, le ton moyen de cette couverture nordiste est près de quatre fois plus négatif que celui du reste du territoire (−4,10 contre −1,09 en score AvgTone GDELT).

Lorsque cette zone est couverte, c'est quasi exclusivement pour des incidents sécuritaires : vols de bétail, tensions sur les axes routiers commerciaux, conflits communautaires liés au foncier, incidents aux marchés frontaliers avec le Niger, le Burkina Faso et le Nigeria. Le gradient nord-sud est systématique et persistant sur toute la période analysée.

2.2 Absence d'outil de centralisation

Ces signaux existent dans les flux GDELT, mis à jour toutes les 15 minutes. Ils ne sont ni agrégés, ni localisés avec précision, ni mis en relation avec les remontées de terrain. Les ONG, les cellules de crise préfectorales et les journalistes d'investigation n'ont aucun outil unifié pour :

- visualiser la distribution géographique des événements sécuritaires en temps réel,

- distinguer les sources médiatiques locales des sources internationales (notamment nigérianes),
- comparer la tension actuelle d'un département à sa moyenne historique,
- croiser un événement GDELT avec un signalement citoyen de même zone.

TERROIR répond directement à ce vide.

3. Architecture du système

L'architecture de BéninScope est organisée en trois couches distinctes, communiquant par des fichiers Parquet persistants et une API REST.

3.1 Vue d'ensemble

Couche	Composant	Rôle
Données	GDELT v2 (masterfilelist + live poller)	Source primaire, 15-min updates
Données	benin_enrichi.parquet	Historique jan 2025 — mai 2026
Données	benin_live.parquet	Fenêtre glissante 30 jours
Données	incidents.db (SQLite)	Signalements citoyens
Backend	FastAPI (Python)	API REST /events, /incidents, /stt
Backend	gdelt_live_poller	Thread daemon, cycle 15 min
Frontend	Vue 3 + Leaflet + Bootstrap 5	Interface carte, filtres, signalement
Dashboard	Streamlit	Analyse approfondie, STT, timeline
Déploiement	Railway + Streamlit Cloud	CI/CD automatique sur push GitHub

3.2 Fusion des données

La fonction `load_combined_data()` fusionne les deux sources Parquet (historique + live) en déduplicant sur `GLOBALEVENTID`. Chaque endpoint de l'API consomme cette vue unifiée, garantissant que les filtres temporels (fenêtre de 30 jours par défaut) opèrent sur l'intégralité des données disponibles, pas uniquement sur les derniers événements live.

4. Pipeline de données GDELT

4.1 Source de données

GDELT v2 publie toutes les 15 minutes un fichier CSV compressé recensant l'intégralité des événements géopolitiques détectés dans la presse mondiale. Chaque ligne correspond à un événement : deux acteurs, un type d'action (code CAMEO), une localisation géographique, un score Goldstein et un score de ton médiatique (AvgTone).

4.2 Filtrage Bénin

Le filtrage géographique s'opère en deux passes :

- Filtre primaire : `ActionGeo_CountryCode == 'BN'` (code ISO Bénin dans GDELT).
- Filtre secondaire (bbox) : latitude 5.5–13.0 N, longitude 0.5–4.0 E, pour éliminer les homonymies géographiques et les événements mal localisés.

Les sources médiatiques nigérianes (domaines .ng, mots-clés 'nigeria', 'naij.com') font l'objet d'un comptage séparé (indicateur IDN%) et peuvent être exclues via un filtre dédié dans l'interface, sans affecter le calcul global.

4.3 Enrichissement des coordonnées

GDELT fournit plusieurs niveaux de géolocalisation par événement. Un système de priorité assigne la coordonnée la plus précise disponible :

Priorité	Source	Description
1 (max)	ActionGeo	Coordonnée exacte du lieu de l'action
2	Actor1Geo	Coordonnée de l'acteur principal béninois
3	Actor2Geo	Coordonnée de l'acteur secondaire béninois
4	centroid_adm1	Centroïde du département identifié
5 (min)	centroid_pays	Centre géographique du Bénin (fallback)

Les événements assignés au centroïde national (niveau 5) reçoivent un jitter gaussien ($\sigma = 0.06$ degré) pour éviter la superposition des marqueurs sur la carte. Le clustering `Leaflet.MarkerCluster` agrège les points proches en bulles numérotées, avec désagrégation automatique au zoom ≥ 9 .

4.4 Historique et remplissage de gap

Un pipeline de remplissage (`scripts/fill_gap_2026.py`) a téléchargé et traité 3 935 fichiers GDELT en parallèle (6 threads) pour couvrir la période avril–mai 2026. Au total, 31 529 événements couvrent la période du 1er janvier 2025 au 28 mai 2026 dans le fichier `benin_enrichi.parquet`.

5. Score de Tension Territorial (STT)

5.1 Définition

Le STT est un indice composite calculé par département sur une fenêtre glissante de 14 jours, comparée à un baseline de 90 jours. Il quantifie l'intensité relative de la tension sécuritaire et médiatique d'une zone par rapport à sa propre moyenne historique.

5.2 Formule

$$\text{STT} = 0,40 \times z_cameo + 0,35 \times z_tone + 0,15 \times z_volume + 0,10 \times z_sources$$

Composante	Poids	Description
z_cameo	40 %	Score CAMEO moyen normalisé (conflictualité type d'action)
z_tone	35 %	Tonalité médiatique moyenne normalisée (AvgTone inversé)
z_volume	15 %	Volume d'événements normalisé sur 14 j vs baseline 90 j
z_sources	10 %	Nombre de sources distinctes normalisé

5.3 Niveaux d'alerte

Niveau	Seuil STT	Signification	Action recommandée
Normal	< 2,0	Tension dans la norme historique	Veille habituelle
Précaution	2,0 – 3,0	Tension modérément supérieure à la moyenne	Vérification avec relais local, surveillance 24h
Alerte	> 3,0	Tension significativement élevée	Contacter relais terrain, informer coordinateur sécurité

5.4 Validation croisée

Les signalements citoyens non validés sont automatiquement rapprochés des événements GDELT sécuritaires récents (rayon 50 km, fenêtre 24 h). Un signalement ayant un événement GDELT correspondant est validé automatiquement par l'algorithme `auto_validate_with_gdelt()`.

6. Plateforme web TERROIR

6.1 Architecture frontend

L'interface est une Single Page Application (SPA) construite avec Vue 3 (CDN, sans bundler), Bootstrap 5 et Leaflet.js. Elle est servie statiquement par FastAPI via StaticFiles. Quatre vues sont accessibles par routing hash :

— Carte live (`#/live`) — carte Leaflet avec événements GDELT et signalements citoyens, filtres par type, fenêtre temporelle (24h à 30j), exclusion Nigeria, clustering.

- Analyse TERROIR (#/terroir) — scores STT par département, graphique Plotly, fiches par département avec niveau d'alerte et phrase explicative.
- Statistiques (#/analysis) — timeline des événements, répartition CAMEO, indicateurs globaux sur la période.
- Signalement (#/report) — formulaire citoyen avec géolocalisation GPS ou sélection par département, liste des 5 signalements récents.

6.2 Temps réel et synchronisation

Les incidents citoyens apparaissent sur la carte dans la seconde suivant la soumission (appel `loadLiveMap()` post-POST). Un intervalle automatique de 60 secondes synchronise les marqueurs pour tous les utilisateurs connectés simultanément. Le statut GDELT se rafraîchit toutes les 2 minutes.

6.3 Localisation temporelle

Tous les horodatages affichés utilisent le fuseau horaire du Bénin (Africa/Porto-Novo, WAT = UTC+1, sans heure d'été). Les timestamps stockés en base sont en UTC avec suffixe Z explicite pour garantir une interprétation correcte par les navigateurs de n'importe quelle région.

7. Insights clés et résultats

Insight	Observation	Implication
Biais de couverture nord	Alibori, Atacora, Borgou : < 4 % des articles GDELT Bénin	La sous-représentation médiatique masque l'intensité réelle des tensions — nécessite une veille active, pas passive
Gradient de ton	Ton nord : -4,10 Sud : -1,09 (ratio 3,8x)	Quand le nord est couvert, c'est quasi exclusivement pour des incidents négatifs
Contamination nigériane	15 à 20 % des événements GDELT Bénin proviennent de médias nigérians (.ng)	Sans filtre, la veille intègre une perspective extérieure potentiellement biaisée — filtrage activable en 1 clic
Latence GDELT	Délai médian source vers GDELT : 15–60 min	Fenêtre suffisante pour une veille préventive ; insuffisante pour une alerte push automatique (V2)
Corrélation GDELT / terrain	Signalements citoyens et événements GDELT proches convergent sur les mêmes foyers	La validation croisée automatique (50 km / 24h) réduit la charge de modération manuelle

8. Déploiement et infrastructure

Backend API	Railway — déploiement automatique sur push GitHub (branche main). Serveur Uvicorn, Python 3.11.
Dashboard	Streamlit Community Cloud — déploiement depuis le même repo GitHub, branche main, fichier dashboard/app.py.
CI/CD	Aucune pipeline custom. Le push GitHub déclenche le redéploiement automatique sur les deux plateformes (< 3 min).
Persistence	benin_enrichi.parquet versionné dans le repo (données historiques). incidents.db versionné avec schéma vide (créé sur Railway au premier démarrage). benin_live.parquet régénéré par le poller toutes les 15 min.
Monitoring	Endpoint /api/health + /api/gdelt/status exposant l'état du poller, le nombre d'événements live et l'heure du dernier cycle (heure Bénin).

9. Divulgence IA

Conformément au règlement du hackathon, l'équipe déclare l'usage des systèmes d'intelligence artificielle suivants :

— Claude Sonnet 4.6 (Anthropic) — assistant au développement logiciel : architecture du pipeline de données, conception de l'algorithme STT, debugging des pipelines Parquet/GDELT, rédaction de

scripts Python, corrections des erreurs de fuseau horaire, génération du présent rapport.

— GDELT Project (NLP intégré) — les scores AvgTone, GoldsteinScale et les codes CAMEO présents dans les données brutes sont produits par les modèles NLP du projet GDELT, extérieurs à l'équipe. Ils sont utilisés comme features, non recalculés.

Aucun modèle propriétaire n'a été entraîné par l'équipe. Aucune donnée personnelle n'a été transmise à un service LLM externe. Les signalements citoyens sont stockés exclusivement en base SQLite locale.

10. Limitations et travaux futurs

10.1 Limitations actuelles

- Précision géographique : 60 à 70 % des événements GDELT Bénin tombent au niveau centroïde département ou pays (pas de coordonnée exacte). Le jitter appliqué est une approximation visuelle, pas une localisation réelle.
- Couverture médiatique : GDELT indexe principalement des sources en ligne en anglais et français. Les événements couverts uniquement par des médias locaux non indexés (radio, presse imprimée) sont absents.
- Persistance signalements : incidents.db est stocké sur le filesystem Railway (éphémère entre redéploiements pour les signalements survenus après le dernier commit). Une base de données managée (PostgreSQL) est recommandée.
- STT baseline : les 90 jours de baseline intègrent des événements des deux sources (historique + live). Sur les premières semaines de vie de la plateforme, le baseline peut être insuffisant pour les petits départements.

10.2 Travaux futurs (V2)

- Géolocalisation par NLP sur contenu d'article : la limitation principale de GDELT est que ses coordonnées sont extraites des métadonnées de surface (titre, entités nommées), sans lecture du corps du texte. Nous prévoyons de développer un modèle NLP dédié qui analysera le contenu complet des articles sources pour extraire les lieux mentionnés (villes, marchés, axes routiers, quartiers), les désambiguïser dans le contexte béninois et produire des coordonnées de précision sous-départementale. Ce modèle enrichirait ou corrigerait les coordonnées GDELT existantes, réduisant drastiquement la part des événements actuellement assignés au centroïde pays (niveau 5).
 - Alertes push (email / SMS) déclenchées automatiquement quand le STT d'un département franchit le seuil Alerte.
 - Migration incidents.db vers PostgreSQL managé pour la persistance multi-déploiement.
 - Intégration de sources locales béninoises non indexées par GDELT (Frissons d'Afrique, L'Événement Précis, etc.).
 - Module de cartographie des acteurs (Actor1 / Actor2) pour détecter les réseaux d'acteurs récurrents dans les zones de tension.
-

11. Equipe et stack technique

11.1 Stack technique

Categorie	Technologies
Traitement de données	Python 3.11, Pandas, PyArrow, Parquet
API backend	FastAPI, Uvicorn, Pydantic
Base de données	SQLite (signalements), Parquet (GDELT)

Source de données	GDELT v2, BigQuery (exploration initiale)
Frontend web	Vue 3 (CDN), Leaflet.js, Leaflet.MarkerCluster, Bootstrap 5, Plotly.js
Dashboard analytique	Streamlit
Déploiement	Railway (API), Streamlit Community Cloud (dashboard)
CI/CD	GitHub (push-to-deploy)
IA / Assistance	Claude Sonnet 4.6 (Anthropic)

Rapport généré automatiquement le 29 mai 2026. BéninScope — TERROIR, Hackathon iSHEERO x DataCamp 2026, Equipe 04.